Analyse syntaxique

Analyse syntaxique

Analyse ascendante LR

Rappel - Analyse LL

Nous avons vu les analyses descendantes LL dans lesquelles

- on cherche à construire une dérivation gauche à partir de l'axiome qui permette d'obtenir le mot d'entrée
- l'automate à pile part de la racine de l'arbre et progresse vers les feuilles en procédant à des remplacements de symboles non terminaux par la partie droite d'une règle dont ils sont partie gauche (parfois appelé expansion)

Exemple - Rappel analyse LL

Pour les expressions

Grammaire de départ

$$\begin{array}{ccc} E & \rightarrow & E+T \mid T \\ T & \rightarrow & T*F \mid F \\ F & \rightarrow & (E) \mid id \\ id & \rightarrow & 1 \mid 2 \end{array}$$

Grammaire obtenue à la section précédente

$$\begin{array}{cccc} E & \rightarrow & TE' \\ E' & \rightarrow & +TE' \mid \varepsilon \\ T & \rightarrow & FT' \\ T' & \rightarrow & *FT' \mid \varepsilon \\ F & \rightarrow & (E) \mid id \\ id & \rightarrow & 1 \mid 2 \end{array}$$

L'analyse LL(1) nous avait conduit à reconstruire pour le mot 2*(1+1) la dérivation gauche en partant de l'axiome :

$$\begin{array}{ll} E & \rightarrow & TE' \rightarrow FT'E' \rightarrow idT'E' \rightarrow 2T'E' \rightarrow 2*FT'E' \rightarrow 2*(E)T' \\ & \rightarrow & 2*(TE')T' \rightarrow \dots \end{array}$$

Analyse *LL* - **Pas toujours possible**

Considérons la grammaire

$$S \rightarrow A \mid B$$

$$A \rightarrow aAb \mid c$$

$$B \rightarrow aBbb \mid d$$

- est-elle ambigüe?
- existe-t-il k > 0 tel qu'elle soit LL(k)?

Idée générale - Analyse LR

Nous allons à présent aborder les analyses ascendantes *LR* **left-to-right**, **rightmost derivation** dans lesquelles

- l'idée est cette fois de construire, à partir d'un mot d'entrée, une dérivation droite : reconstruire « à l'envers » la dérivation à partir des feuilles de l'arbre
- partant des feuilles, on va cette fois remplacer une suite de symboles correspondant à la partie droite d'une règle par sa partie gauche (aussi appelé réduction)

➤ Pour ce cours, référence principale : Dragon Book, 2007

Exemple - Expressions

Idée générale - Décalage/Réduction

En analysant un mot de gauche à droite, on cherche à se ramener à l'axiome en remplaçant un peu à la fois les parties droites de règles contruites par la partie gauche correspondante

En cours d'analyse, un proto-mot $\alpha\beta u$ est construit avec $u\in\Sigma^*$ la poursuite de la recherche peut considérer deux cas :

- il existe une règle $T \to \beta$ et une réduction est appliquée pour poursuivre avec le proto-mot αTu
- u = xu' avec $x \in \Sigma$, on applique un décalage pour poursuivre l'analyse avec le proto-mot $\alpha\beta'u'$ et $\beta' = \beta x$

Cette stratégie va mener à une dérivation droite, en effet, chaque fois qu'on applique une règle $T \to \beta$, le facteur du mot qui suit β est un mot de Σ^*

Idée générale - Décalage / Réduction - Ex id * (id + id) (1/2)

Grammaire exemple « fil rouge » tirée du Dragon Book (ch 4) :

$$oxed{E
ightarrow E+T\mid T\mid T
ightarrow T*F\mid F\mid F
ightarrow (E)\mid id}$$

Analyse

α	и	
ε	id*(id+id)	shift
id	*(id + id)	F o id
F	*(id + id)	$T \rightarrow F$
T	*(id + id)	shift
T*	(id + id)	shift
T*(id + id)	shift
T*(id	+id)	F o id
T*(F	+id)	$T \rightarrow F$
T * (T	+id)	E o T

$$\begin{array}{c|cccc} T*(E & +id) & shift \\ T*(E+ & id) & shift \\ T*(E+id &) & F \rightarrow id \\ T*(E+F &) & T \rightarrow F \\ T*(E+T &) & E \rightarrow E+T \\ T*(E &) & shift \\ T*(E) & \varepsilon & F \rightarrow (E) \\ T*F & \varepsilon & T \rightarrow T*F \\ T & \varepsilon & E \rightarrow T \\ E & \varepsilon & success \\ \end{array}$$

Dérivation <u>droite</u> produite : $E \to T \to T * F \to T * (E) \to T * (E+T) \to T * (E+F) \to T * (E+id) \to T * (T+id) \to \dots$

Idée générale - Décalage / Réduction - Ex id * (id + id) (2/2)

Grammaire :
$$E \rightarrow E + T \mid T \mid T \rightarrow T * F \mid F \mid F \rightarrow (E) \mid id$$

Remarque

α	и	
ε	id*(id+id)	shift
id	*(<i>id</i> + <i>id</i>)	F o id
F	*(<i>id</i> + <i>id</i>)	$T \rightarrow F$
T	*(<i>id</i> + <i>id</i>)	-shift
<i>I</i> *	(id+id)	-shift
T	*(<i>id</i> + <i>id</i>)	$E \rightarrow T$
E	*(<i>id</i> + <i>id</i>)	shift
E*	(id + id)	shift
E * (id + id)	shift
E * (id	+ <i>id</i>)	shift
E*(id+	id)	shift
E*(id+id))	shift
E*(id+id)		fail

→On souhaite évidemment éviter le non déterminisme

Intuition

- Nous essayons de réduire les suffixes de la partie en cours d'analyse
- se prête bien à l'utilisation d'une pile
 - Nous allons construire des automates à pile, ces automates sont aussi appelés shift-reduce car ils peuvent
 - shift (décalage de l'entrée) : lire un symbole de l'entrée et l'empiler
 - reduce (réduction) : réduire une règle, soit remplacer un mot en sommet de pile qui correspond à la partie droite d'une règle par la partie gauche de la règle
 - · Problème de déterminisme, à chaque étape
 - · choix entre shift et reduce
 - choix de la partie du sommet de pile réduire, aussi appelé « handle »
 - · choix de la règle à appliquer

Théorie - Automate shift/reduce



 $\stackrel{/!}{\sim}$ On représente le fond de pile à gauche et le sommet de pile à droite

Soit $\mathcal{G} = (\Sigma, V, S, R)$ une grammaire, on construit un automate à pile généralisé $\mathcal{B} = (\Sigma, V \cup \Sigma, \varepsilon, \{q_0\}, q_0, \emptyset, \delta)$:

- l'automate accepte le mot lorsque la pile contient uniquement le symbole S
- les transitions sont généralisées (on omet q_0) $(\Sigma \cup V)^* \times (\Sigma \cup \{\varepsilon\})$ dans $(\Sigma \cup V)$ et composées de :
 - shift : $\{(\varepsilon, x, x) \mid x \in \Sigma\}$ ⇒ Sans toucher au sommet de pile, on empile x après l'avoir lu sur l'entrée
 - reduce : $\{(\alpha, \varepsilon, T) \mid T \to \alpha \in R\}$ \Rightarrow si le mot α est en sommet de pile et qu'il existe une règle $T \to \alpha$, sans avancer dans l'entrée, on peut remplacer α par T en sommet de pile

Pourquoi cela fonctionne-t-il?

Intuition. En cours de dérivation droite, le proto-mot a une forme αTu où $T \in V$ est le prochain symbole à dériver et $u \in \Sigma^*$, la règle utilisée pour dériver T peut produire ou pas le prochain non terminal à dériver :

Cas 1	Pile	Mot	Action
α Tu $ ightarrow lphaeta$ Zvu $ ightarrow lphaeta\gamma$ vu	$\alpha\beta\gamma$	vu	reduce
application de $T \rightarrow \beta Z v$	$\alpha \beta Z$	vu	shift*
puis $Z \rightarrow \gamma$	$\alpha \beta Z v$	и	reduce
	αT	и	
Cas 2	Pile	Mot	Action
$\alpha Tu \rightarrow \alpha' Zwvu \rightarrow \alpha' \gamma wvu$	$\alpha'\gamma$	wvu	reduce
application de $T \rightarrow v$	$\alpha'Z$	wvu	shift*
puis $Z o \gamma$	α′ Zwv	и	reduce
	α' ZwT	и	

Proposition. L'automate shift/reduce reconnaît le langage généré par la grammaire

k-conflits

Soient $x, x' \in \Sigma$, $T, T' \in V$, $u, u', v \in \Sigma^*$ et $\alpha, \beta, \alpha', \beta' \in (\Sigma \cup V)^*$

• Il existe un k-conflit shift – reduce si il existe deux calculs de l'automate

$$\begin{array}{cccccc} \beta\alpha & \xrightarrow{\varepsilon} & \beta T & \xrightarrow{u} S \\ \beta\alpha & \xrightarrow{x} & \beta\alpha x & \xrightarrow{v} S \end{array}$$

tels que $First_k(u) = First_k(xv)$

 Il existe un k-conflit reduce – reduce si il existe deux calculs de l'automate

$$\begin{array}{cccc} \beta\alpha & \xrightarrow{\varepsilon} & \beta T & \xrightarrow{u} S \\ \beta'\alpha' & \xrightarrow{\varepsilon} & \beta'T' & \xrightarrow{u'} S \end{array}$$

tels que $\beta \alpha = \beta' \alpha'$ et $First_k(u) = First_k(u')$

Grammaires augmentées

Problème : par exemple la grammaire $S \to Sa \mid a$, n'a aucun conflit mais admet des étapes de calcul pour lesquels l'axiome est seul en pile ightharpoonup problème de décision de l'arrêt

Définition

Soit $\mathcal{G}=(\Sigma,V,S,R)$ une grammaire, la **grammaire augmentée** de \mathcal{G} est $\mathcal{G}'=(\Sigma,V\cup\{S'\},S',R\cup\{S'\to S\})$ avec $S'\not\in V$

Une grammaire est LR(k) si sa grammaire augmentée n'a aucun k-conflit

Exemple. Grammaire augmentée pour les expressions

$$\begin{array}{ccc} E & \rightarrow & E+T \mid T \\ T & \rightarrow & T*F \mid F \\ F & \rightarrow & (E) \mid id \end{array}$$

$$\begin{array}{ccc} E' & \rightarrow & E \\ E & \rightarrow & E+T \mid T \\ T & \rightarrow & T*F \mid F \\ F & \rightarrow & (E) \mid id \end{array}$$

Grammaire LR(k) - Remarques

Remarques sur les LR

- La hiérarchie des grammaires LR(k) est stricte
- On ne peut pas décider s'il existe un k tel qu'une grammaire donnée soit LR(k)
- Tout langage déterministe peut être engendré par une grammaire LR(1)

Liens LL et LR

- Toute grammaire LL(k) est LR(k)
- On peut décider si une grammaire LR(k) est LL(k)
- On ne peut pas décider s'il existe un k tel qu'une grammaire donnée LR(i) soit LL(k)

Construction d'un analyseur LR

Pour construire un analyseur, il faut savoir décider à tout moment :

- s'il faut appliquer un shift ou un reduce
- s'il s'agit de réduire, quelle règle appliquer
- · quand s'arrêter et si l'arrêt note un succès ou un échec
- sans anticiper la lecture des symboles de l'entrée

Nous allons construire un automate qui va permettre de guider l'analyse en mémorisant à quel stade l'analyse en est

Analyseur LR(k)

Soit $G = (\Sigma, V, S', R)$ une grammaire augmentée

L'analyseur LR(k) de G est défini par

- un automate fini déterministe dit « automate des contextes » qui va assurer le contrôle
- une fonction action qui à un état de Q et un mot $u \in \Sigma^*$ avec $|u| \le k$ associe une action success, fail, shift, ou une action reduce $_{T \to \alpha}$ pour les $T \to \alpha \in R$

Une configuration de l'analyseur est une paire $(\alpha, u) \in (\Sigma \cup V)^* \times \Sigma^*$ dans laquelle α est le contenu de la pile et u le mot restant à lire sur l'entrée

Dans une configuration (α, u) l'analyseur LR(k) effectue le pas $action(goto(g_0, \alpha), First_k(u))$

Architecture d'un analyseur syntaxique LR

L'algorithme d'analyse syntaxique *LR* va toujours s'appuyer sur

- une entrée : sur laquelle on lit des mots de l'alphabet terminal
- · une sortie
- une table d'analyse syntaxique permettant de décider l'action à accomplir, et de connaitre la fonction de transition goto de l'automate des contextes
- · une pile

Dans la définition précédente, on indique que dans une configuration (α, u) l'analyseur LR(k) effectue le pas $action(goto(q_0, \alpha), First_k(u))$

- pour éviter de recalculer les goto à chaque pas, il suffirait de stocker l'état courant dans la pile
- nous verrons que par construction de l'automate des contextes, il suffit de garder l'état courant

Analyse syntaxique

LR(0)

0-item ou item

Un **0-item** ou **item** d'une grammaire $\mathcal{G}=(\Sigma,V,S,R)$ est une règle de R dans la partie droite de laquelle un point a été inséré : intuitivement, il sépare le début de la partie droite qui a déjà été reconnue de la fin de la partie droite que l'on espère trouver

Exemple

```
\begin{array}{ccccc} \text{La règle} & T & \rightarrow & \alpha\beta\gamma \\ \text{donne} & T & \rightarrow & \bullet\alpha\beta\gamma \\ & T & \rightarrow & \alpha\bullet\beta\gamma \\ & T & \rightarrow & \alpha\beta\bullet\gamma \\ & T & \rightarrow & \alpha\beta\gamma\bullet \end{array}
```

- ightharpoonup lpha eta
 ightharpoonup lpha eta
 ightharpoonup lpha eta
 ightharpoonup lpha eta et que l'on espère trouver une chaîne qui se dérive de γ
- $ightharpoonup \alpha \beta \gamma
 ightharpoonup$ indique que l'on peut envisager de réduire $\alpha \beta \gamma$ en T

Remarque $T \to \varepsilon$ a pour seul item $T \to \bullet$

0-item - Exemple

$$S' \rightarrow S$$

 $S \rightarrow aSb \mid ab$

Les 0-items de la grammaire

 $\mathcal{S}' \rightarrow \bullet \mathcal{S}$

 $S' \rightarrow S ullet$

 $S \rightarrow \bullet aSb$

 $S \rightarrow a \cdot Sb$

 $S \rightarrow aS \bullet b$

 $S \rightarrow aSb \bullet$

 $S \rightarrow \bullet ab$

 $S \rightarrow a \bullet b$

S o ab ullet

item valide

Tout les préfixes d'un proto-mot ne peuvent pas apparaître sur la pile d'un analyseur *shift – reduce* car l'analyseur doit réduire les éléments en sommet de pile quand c'est possible avant de décaler

Un item $T \to \alpha \bullet \beta$ est valide dans le contexte γ s'il existe une dérivation droite

$$\mathcal{S}' \underset{*}{\rightarrow} \delta \mathit{Tu} \rightarrow \delta \alpha \beta \mathit{u} \ \mathrm{avec} \ \gamma = \delta \alpha$$

On note $\mathit{I}_{0}(\gamma)$ l'ensemble des items valides dans le contexte γ De plus

- si β est vide, alors un *reduce* est utile
- si β n'est pas vide, un *shift* est utile

Clôture d'un ensemble d'items

Soit I un ensemble d'items, la clôture de I, notée clos(I) est le plus petit ensemble d'items tel que :

- I ⊆ clos(I)
- si $T \to \alpha \bullet U\beta \in clos(I)$ et $U \to \gamma$ alors $U \to \bullet \gamma \in clos(I)$

Intuition. Si nous considérons $\alpha \bullet U\beta$ alors nous espérons trouver un mot qui se dérive de $U\beta$, le préfixe de ce mot sera obtenu par dérivation de U

Exemple

$$clos(\{S' o ullet S\}) = \{ egin{array}{ccc} S' o ullet S \\ S o ullet A \\ S' o S \\ S o A \mid B \\ A o aAb \mid c \\ B o aBbb \mid d \end{array} \ \ \, \begin{array}{cccc} A o ullet S \\ A o ullet aAb \\ A o ullet aBbb \\ B o ullet aBbb \\ B o ullet a B \\ \end{array}$$

Clôture d'un ensemble d'items - Exemple

Exemple de la grammaire augmentée pour les expressions

$$clos(\{E' \rightarrow \bullet E\}) = \{ E' \rightarrow \bullet E \\ E \rightarrow \bullet E + T \\ E \rightarrow \bullet T \\ T \rightarrow \bullet T * F \\ E \rightarrow E + T \mid T \\ T \rightarrow T * F \mid F \\ F \rightarrow \bullet (E) \\ Id \}$$

$$clos(\{T \rightarrow T * \bullet F\}) = \{ T \rightarrow T * \bullet F \\ F \rightarrow \bullet (E) \\ F \rightarrow \bullet id \}$$

Fonction *goto*

Soit *I* un ensemble d'items et *x* un symbole de $\Sigma \cup V$, alors

$$goto(I,x) = clos(\{T \to \alpha x \bullet \beta \mid T \to \alpha \bullet x \beta \in I\})$$

Intuition

Cette fonction va permettre de définir les transitions de l'automate dont les états seront des ensembles d'items

Exemple

```
S' 	o S

S 	o A \mid B

A 	o aAb \mid c

B 	o aBbb \mid d

I = \{A 	o \bullet aAb, B 	o d \bullet \}

goto(I, a) = \{A 	o a 	o Ab \land A 	o \bullet aAb \land A 	o \bullet A 	o \bullet Ab \land A 	o \bullet A
```

goto - Exemple pour les expressions

```
Notons I = clos(\{E' \to \bullet E\}) Calculons
I = \{E' \to \bullet E + T & \bullet \text{ calcul}
E \to \bullet E + T & \text{ calcul}
E \to \bullet T & \text{ goto}(I, id)
T \to \bullet T * F
T \to \bullet F
F \to \bullet (E) & \bullet \text{ ajoute}
F \to \bullet id & \bullet \text{ calcul}
goto(I, id)
```

Calculons *goto*(*I*, *id*)

- ajouter F → id•
- calculer la clôture : rien à ajouter

$$goto(I, id) = \{F \rightarrow id \bullet\}$$

Calculons goto(I, T)

- ajouter $E \rightarrow T \bullet$, $T \rightarrow T \bullet *F$
- calculer la clôture : rien à ajouter

$$goto(I,id) = \{E \to T \bullet, T \to T \bullet *F\}$$

Calculons goto(I,()

- ajouter $F \rightarrow (\bullet E)$
- calculer la clôture : $goto(I, () = \{F \to (\bullet E), E \to \bullet E + T, E \to \bullet T, T \to \bullet T * F, T \to \bullet F, F \to \bullet (E), F \to \bullet id\}$

Remarques

L'ensemble des items valides a des propriétés intéressantes que nous ne démontrerons pas. Pour tout $\gamma \in (\Sigma \cup V)^*$:

- $I_0(\gamma)$ est clos
- $goto(I_0(\gamma), x) \subseteq I_0(\gamma x)$

Automate des contextes

Nous allons construire un automate

- dont les états sont construits à partir des items
- · dont les transitions sont données par la fonction goto

Soit $\mathcal{G} = (\Sigma, V, S, R)$ une grammaire, alors son automate des contextes $\mathcal{C} = (\Sigma \cup V, Q, q_0, F, goto)$ est tel que :

- Q un ensemble d'ensembles d'items
- $q_0 = clos(\{S' \to \bullet S\})$ (avec S' l'axiome de la grammaire augmentée de $\mathcal G$
- F = Q

Remarque. En fait, pour tout $\gamma \in (\Sigma \cup V)^*$, $I_0(\gamma) = goto(q_0, \gamma)$ en pratique on ne va pas utiliser tous les ensembles d'items possibles mais seulement ceux qui sont utiles : on prend Q = l'ensemble canonique d'ensemble d'items

Construction de l'ensemble canonique d'ensembles d'items

Cet ensemble canonique C permet de construire directement l'automate des contextes (ou automates LR(0)) avec l'ensemble d'états adéquat, c'est le plus petit ensemble tel que

- $clos(\{S' \rightarrow \bullet S\}) \in C$
- $\forall x \in \Sigma \cup V, \forall I \in C, (goto(I, x) \neq \emptyset) \Rightarrow (goto(I, x) \in C)$

L'algorithme de construction de cet ensemble part de $clos(\{S' \to \bullet S\})$ et sature l'ensemble par itérations successives

→Tous les états de l'automate des contextes sont accessibles

Automate des contextes - Exemple




Table des actions de l'analyse SLR

Soit *I* un ensemble d'items, $x \in \Sigma$, et $u \in \Sigma \cup \{\varepsilon\}$

- action(I, x) = shift si ∃T → α xβ ∈ I
 ⇒ on peut ajouter x à la construction de partie droite de règle en cours
- action(I, u) = reduce_{T→α} si T → α• ∈ I, u ∈ Follow(T) et T ≠ S'
 On a analysé un mot qui se dérive à partir de α et le suffixe u peut suivre la dérivation de la variable T
- action(I,ε) = success si S' → S• ∈ I
 Les réductions successives ont mené à l'axiome
- action(I, u) = fail sinon

→ Dans les autres cas, on est bloqué

Table des actions de l'analyse SLR - Exemple (1/2)

Rappel de la grammaire

Une grammaire est *SLR* s'il n'y a pas de conflit dans la table *action* de son analyseur *SLR*

Automate des contextes - Rappel




Table des actions de l'analyse SLR - Exemple (2/2)

	а	b	С	d	#
i ₀	shift		shift	shift	
<i>i</i> ₁	shift		shift	shift	
<i>i</i> ₂		$reduce_{A ightarrow c}$			$reduce_{A o c}$
<i>i</i> ₃		$reduce_{B ightarrow d}$			$reduce_{B ightarrow d}$
i ₄		shift			
<i>i</i> ₅		shift			
<i>i</i> ₆		$reduce_{A ightarrow aAb}$			$reduce_{A ightarrow aAb}$
<i>i</i> ₇		shift			
i ₈		$reduce_{B o aBbb}$			$reduce_{B ightarrow aBbb}$
i 9					success
<i>i</i> ₁₀					$\textit{reduce}_{\mathcal{S} o \mathcal{A}}$
<i>i</i> ₁₁					$reduce_{S o B}$

Analyse SLR

Exemple du mot adbb


Configuration

Pile	Mot	action
α	и	$action(goto(i_0, \alpha), First(u))$
ε	adbb#	shift
а	dbb#	shift
ad	bb#	$reduce_{B ightarrow d}$
аВ	bb#	shift
aBb	<i>b</i> #	shift
aBbb	#	$\textit{reduce}_{\textit{B} ightarrow \textit{aBbb}}$
В	#	$\textit{reduce}_{\mathcal{S} o \mathcal{B}}$
S	#	success

Les limites de l'analyse SLR

Exemple de grammaire (toujours du Dragon Book) non ambigüe

$$\begin{array}{cccc} S' & \rightarrow & S \\ S & \rightarrow & G = D \mid D \\ G & \rightarrow & *D \mid id \\ D & \rightarrow & G \end{array}$$



Dans la table on a pour la case $action(i_1, =)$, shift mais aussi $reduce_{D \to G}$ $car = \in Follow(D)$, il y a donc un conflit

► L'analyse *SLR* est donc simple à mettre en œuvre mais pas assez puissante pour toutes les grammaires

Analyse syntaxique

Analyse LR(1)

Limites de l'analyse SLR

Exemple de grammaire (toujours du Dragon Book)

$$\mathcal{S}' \rightarrow \mathcal{S}$$

$$S \rightarrow G = D \mid D$$

$$G \rightarrow *D \mid id$$


$$D \rightarrow G$$

La grammaire est non ambiguë (rappel : c'est indécidable), exemple de deux dérivations

$$S' \rightarrow S \rightarrow D \rightarrow G \rightarrow *D \rightarrow *G \rightarrow *id$$

$$S' \rightarrow S \rightarrow G = D \rightarrow G = G \rightarrow G = id \rightarrow *D = id \rightarrow *G = id \rightarrow *id = id$$

Exemple



Exemple

Nous avons $= \in Follow(D)$, donc dans la table d'action nous allons trouver

$$\textit{action}(\textit{i}_2, =) = \left\{ egin{array}{l} \textit{shift} \\ \textit{reduce}_{\textit{D}
ightarrow \textit{G}} \end{array}
ight.$$

donc la table contient un conflit et la grammaire n'est pas LR(0)

ightharpoonup L'analyse SLR est donc simple à mettre en œuvre mais pas assez puissante pour toutes les grammaires

Nous allons voir des analyses plus puissantes : elles ne permettent pas d'analyser sans conflit toutes les grammaires, mais sont en général suffisantes pour les langages de programmation

Principes de l'extension

- Afin d'augmenter la puissance de l'analyse, on va désormais s'autoriser l'exploration d'un symbole en avant pour prendre une décision sur l'action à appliquer
- Il s'agit d'un « lookahead » comme dans le cas des LL
- · On va généraliser la notion d'item sous la forme

$$[T \to \alpha \bullet \beta, x]$$

en considérant pour x les symboles terminaux qui peuvent suivre T à ce stade de l'analyse, et donc $x \in Follow(T)$

• Le comportement de l'analyseur va être modifié en conséquence : dans un état contenant $[T \to \alpha \bullet, x]$ la réduction $T \to \alpha$ est appliquée si et seulement si le prochain symbole d'entrée est x

Calcul des 1-items

La définition des 0—items est étendue pour inclure une information supplémentaire : un symbole terminal (ou fin de chaîne)

<u>Définition</u> Les 1-items pour la grammaire $\mathcal{G} = (\Sigma, V, S, R)$ sont les

$$[T \to \alpha \bullet \beta, x]$$
 avec $T \to \alpha \beta \in R$ et $x \in \Sigma \cup \{\#\}$

Remarques

- Si $\beta \neq \varepsilon$, le symbole x n'a pas d'effet, il n'influence donc pas les actions shift
- Si β = ε alors l'action reduce_{T→α} ne sera effectuée que dans une configuration (γ, ν) avec x = First(ν)
- Cette méthode va générer un grand nombre d'items

1-item valide

Un 1-item $[T \to \alpha \bullet \beta, x]$ est valide dans le contexte γ s'il existe dans $\mathcal G$ une dérivation droite (on note $I_1(\gamma)$ l'ensemble des 1-items valides pour γ)

$$S' \underset{*}{\rightarrow} \delta Tu \rightarrow \delta \alpha \beta u$$
 avec $\gamma = \delta \alpha$ et $x = First(u)$ ou $x = \#$ en pratique

Exemple

Grammaire

$$S' \rightarrow S$$

$$S \rightarrow A \mid B$$

$$A \rightarrow aAb \mid c$$

$$B \rightarrow aBbb \mid d$$

Dérivation

Par exemple $[A \rightarrow a \bullet Ab, b]$ est valide dans le contexte $\gamma = aaa$ car on a

$$S' \rightarrow \delta Tu \rightarrow \delta \alpha \beta u$$

 $S' \rightarrow aaAbb \rightarrow aaaAbbb$

avec
$$\gamma = aaa$$
 et $b \in First(bb)$

Clôture d'un ensemble de 1-items

Soit I un ensemble d'1-items, la clôture de I, notée clos(I) est le plus petit ensemble d'items tel que :

- I ⊆ clos(I)
- si $[T \to \alpha \bullet U\beta, x] \in clos(I)$ et $U \to \delta$ et $y \in First(\beta x)$ alors $[U \to \bullet \delta, y] \in clos(I)$

Pourquoi?

Pour $[T \to \alpha \bullet U\beta, x]$ valide pour un contexte γ , il existe une dérivation droite

$$\mathcal{S} \underset{*}{\rightarrow} \eta \mathit{Txu} \rightarrow \eta \alpha \mathit{U} \beta \mathit{xu} \ \mathsf{avec} \ \gamma = \eta \alpha$$

donc $[U \to \bullet \delta, y]$ est valide dans le contexte γ avec $y \in First(\beta x)$

$$S \underset{*}{\rightarrow} \eta T x u \rightarrow \eta \alpha U \beta x u = \gamma U \beta x u \rightarrow \gamma \delta \beta x u$$

Clôture d'un ensemble de 1-items - Exemple

```
clos(\{[S' \rightarrow \bullet S, \#]\}) = \{ \begin{array}{ccc} [S' \rightarrow \bullet S, \#], \\ [S \rightarrow \bullet G = D, \#], \\ [S \rightarrow \bullet D, \#], \\ [S \rightarrow \bullet D, \#], \\ [G \rightarrow \bullet * D, =], \\ [G \rightarrow \bullet id, =], \\ [D \rightarrow \bullet G, \#] \\ [G \rightarrow \bullet * D, \#], \\ [G \rightarrow \bullet * D, \#], \\ [G \rightarrow \bullet * D, \#], \\ [G \rightarrow \bullet id, \#] \\ \\ \}
```

Fonction *goto*

Soit *I* un ensemble d'1-items et *x* un symbole de $\Sigma \cup V$, alors

$$goto(I, x) = clos(\{[T \rightarrow \alpha x \bullet \beta, y] \mid [T \rightarrow \alpha \bullet x\beta, y] \in I\})$$

Remarques

L'ensemble des 1-items valides a les mêmes propriétés intéressantes que I_0 que nous ne démontrerons pas. Pour tout $\gamma \in (\Sigma \cup V)^*$:

- $I_1(\gamma)$ est clos
- $goto(I_1(\gamma), x) \subseteq I_1(\gamma x)$

Automate des contextes

Soit $G = (\Sigma, V, S, R)$ une grammaire, alors son automate des contextes $C_1 = (\Sigma \cup V, Q, q_0, F, goto)$ est tel que :

- Q un ensemble d'ensembles d'1—items
- $q_0 = clos(\{[S' \to \bullet S, \#]\})$ (avec S' l'axiome de la grammaire augmentée de \mathcal{G})
- *F* = *Q*

On ne considère par la suite que les états accessibles

Remarque. L'automate C_1 calcule les 1-items valides, pour tout $\gamma \in (\Sigma \cup V)^*$, $I_1(\gamma) = goto(q_0, \gamma)$

Automate des contextes - Exemple LR(1)




Table des actions

Soit *I* un ensemble d'1-items, $x \in \Sigma$, et $y \in \Sigma \cup \{\#\}$

- $action(I, x) = shift \text{ si } \exists [T \rightarrow \alpha \bullet x\beta, y] \in I$
- $action(I, y) = reduce_{T \to \alpha}$ si $[T \to \alpha \bullet, y] \in I$ et $T \neq S'$
- $action(I, \#) = success \text{ si } [S' \rightarrow S \bullet, \#] \in I$
- action(I, u) = fail sinon

La grammaire \mathcal{G} est LR(1) si et seulement si il n'y a pas de conflit dans la table action de son analyseur LR(1)

Table des actions - Exemple

$$\begin{vmatrix} S \to G \bullet = D, \# \\ D \to G \bullet, \# \end{vmatrix}$$

Comme
$$S \to G \bullet = D, x \in I_2$$
 avec $x = \#$

$$shift \in action(I_2, =)$$

Est-ce qu'une réduction s'applique?

La définition indique

$$action(I_2, =) = reduce_{T \to \alpha} \text{ si } [T \to \alpha \bullet, =] \in I, \text{ et } T \neq S'$$

ce qui n'est pas le cas ici puisque l'item qui contient $D \to G \bullet$ en première composante contient # en deuxième composante

Le conflit est donc levé

Remarques

Comparaison des analyseurs LR(0) et LR(1)

- Les actions shift sont les mêmes dans les deux cas
- Les actions reduce de l'analyseur LR(1) sont des actions reduce de l'analyseur LR(0)
- Si $[T \to \alpha \bullet \beta, x] \in I_1(\gamma)$ alors $T \to \alpha \bullet \beta \in I_0(\gamma)$ et $x \in Follow(T)$
- Si $T \to \alpha \bullet \beta \in I_0(\gamma)$ alors $\exists x \in \Sigma \cup \{\#\}$ tel que $[T \to \alpha \bullet \beta, x] \in I_1(\gamma)$

Problèmes

La classe *SLR* est intéressante mais trop faible pour des cas qui se rencontrent dans les langages de programmation

Les classes LR(k) avec $k \ge 2$ vont conduire à une taille de table d'analyse beaucoup trop importante en raison des lookahead. Même la table LR(1) aurait en pratique plusieurs milliers d'états pour les langages de programmation classiques

On utilise en pratique un compromis entre LR(0) et LR(1): LALR

Analyse syntaxique

Analyse LALR

Principe le l'analyse LALR


Look-Ahead LR est une classe d'analyseurs dont l'automate est obtenu en fusionnant les états de l'automate LR(1) qui diffèrent uniquement par leur deuxième composante

L'automate va donc avoir autant d'états que l'automate LR(0) (puisque les premières composantes des 1-items sont les 0 – items)

On conserve néanmoins l'information de look-ahead. Quand il n'y a pas de conflit dans la table LR(1)


- on peut montrer que l'on introduit pas de conflit shift/reduce
- on peut néanmois introduire des conflits reduce/reduce

Exemple



ightharpoonup L'automate a la même structure l'automate LR(0), la table des actions évite le conflit en i_2 comme l'analyse LR(1)

Exemple - Automate LR(1)




Exemple - Table d'actions

	а	b	С	d	e	#
<i>i</i> ₀	s	S				
<i>i</i> ₁			s			
i ₂			s			
<i>i</i> ₃				s		
<i>i</i> ₄					S	
<i>i</i> 5				$r_{A \rightarrow c}$	$r_{B o c}$	
<i>i</i> ₆				$r_{B o c}$	$r_{A o c}$	
<i>i</i> ₇				s		
<i>i</i> ₈					s	
i 9						$r_{\mathcal{S} o aAd}$
<i>i</i> ₁₀						$r_{\mathcal{S} o aBe}$
<i>i</i> ₁₁						$r_{\mathcal{S} ightarrow bBd}$
<i>i</i> ₁₂						$r_{\mathcal{S} ightarrow \mathit{bAe}}$
<i>i</i> ₁₃						success

► La grammaire est *LR*(1)

Exemple - Automate *LALR*



Exemple - Conflit dans l'état i₅₆

$$i_{56}$$
 $A \rightarrow c \bullet, d/e$ $B \rightarrow c \bullet, d/e$

On modifie la table d'actions :

- comme $[A \rightarrow c \bullet, d] \in i_{56}$, $reduce_{A \rightarrow c} \in action(i_{56}, d)$
- comme $[B \rightarrow c \bullet, d] \in i_{56}$, $reduce_{B \rightarrow c} \in action(i_{56}, d)$

conflit reduce/reduce

- comme $[A \rightarrow c \bullet, e] \in i_{56}$, $reduce_{A \rightarrow c} \in action(i_{56}, e)$
- comme $[B \rightarrow c \bullet, e] \in i_{56}$, $reduce_{B \rightarrow c} \in action(i_{56}, e)$

conflit reduce/reduce

Cette grammaire (très simple) n'est pas LALR, cet exemple illustre l'introduction possible de conflits reduce-reduce lorsque l'on essaie de se ramener de LR(1) à LALR

Analyse syntaxique

CYK - Thanks to Benoît Sagot

Pourquoi?

Les langages de programmation sont définis par des grammaires algébriques qui ne sont pas ambiguës

Les algorithmes pour les CFG non ambiguës (« déterministes ») sont relativement simples (LR, LALR, ...)

Le langage naturel est ambigu, les algorithmes que nous avons vus ne conviennent pas, cela a abouti au développement d'algorithmes d'analyse des grammaires algébriques générales (c'est-à-dire pas seulement déterministes) :

- CYK ⇒nous allons voir un exemple de celui-ci
- Earley
- GLR

Principes

- L'algorithme de base Cocke Younger Kasami, alias CYK, résout un problème d'appartenance : ce n'est pas un algorithme d'analyse en soi
- Une implémentation de l'algorithme CYK est un identificateur, pas un analyseur mais il peut facilement être adapté pour devenir un algorithme d'analyse
- Le problème d'appartenance est simple : soient une grammaire algébrique et une chaîne d'entrée, la chaîne d'entrée appartient-elle au langage défini par la grammaire?
- La grammaire doit être en forme normale de Chomsky. Pour rappel, les règles doivent avoir l'une des formes suivantes :
 - $S \rightarrow TU$, avec T et U des non terminaux
 - $S \rightarrow x$, avec x un terminal
 - $S \rightarrow \varepsilon$
- C'est un algorithme ascendant basé sur la programmation dynamique

Algorithme

```
Entrée : mot u, n = |u|
S de taille n, n, |V|
S initialisé à 0
for i = 1 à n do
  for all T \rightarrow x \in R do
     if u[i] = x then
       S[i,i,T] = 1
     end if
  end for
end for
```

```
for k de 1 à n − 1 do
  for i de 1 à n-k do
    i = i + k
    for all T \rightarrow UX \in R do
       for r de i à j-1 do
         if S[i,r,U] = S[r+1,j,X] = 1 then
            S[i,j,T]=1
         end if
       end for
    end for
  end for
end for
```

Idée de l'algorithme

Soient $G = (\Sigma, V, S, R)$ une grammaire en forme normale de Chomsky et $u = x_1 x_2 \dots x_n$ un mot

L'algorithme est itératif et construit une table S de n sur n tel que $S_{i,j}$ soit l'ensemble des variables qui produisent $x_i \dots x_j$

- Étape 1 : traitement des facteurs de longueur 1. Pour chaque x_i,
 S_{i-1,i} = {T ∈ V | T → x_i}
- Étape 2 : traitement des facteurs de longueur 2. Pour chaque $x_i x_{i+1}$, $S_{i-1,i+1} = \{T \in V \mid T \to x_i x_{i+1}\}$
- ...
- •
- Étape n : traitement des facteurs de longueur n. Pour $x_1 \dots x_n$, $S_{0,n} = \{T \in V \mid T \to x_1 \dots x_n\}$

Alors $u \in \mathcal{L}(\mathcal{G})$ si et seulement si $\mathcal{S}_{0,n} = \{S\}$

Table

\$ 0,4			
\$ 0,3	S 1,4		
\$ 0,2	S 1,3	\$ 2,4	
\$ 0,1	\$ 1,2	\$ 2,3	S 3,4
<i>x</i> 1	x2	<i>x</i> 3	x4

Exemple (1/8)

	1		
\$ 0,4			
S 0,3	S 1,4		
S 0,2	S 1,3	S 2,4	
\$ 0,1	S 1,2	S 2,3	S 3,4
с	b	b	a

S 0,4			
S 0,3	S 1,4		
S 0,2	S 1,3	S 2,4	
{A,C}	{B}	{B}	{A}
С	b	b	а

Exemple (2/8)

	1		
S 0,4			
S 0,3	S 1,4		
S 0,2	S 1,3	S 2,4	
S 0,1	S 1,2	S 2,3	S 3,4
С	b	b	а

S 0,4			
S 0,3	S 1,4		
{S,C}	S 1,3	S 2,4	
{A,C}	{B}	{B}	{A}
с	b	b	a

Exemple (3/8)

S 0,4			
S 0,3	\$ 1,4		
S 0,2	S 1,3	S 2,4	
S 0,1	S 1,2	S 2,3	S 3,4
С	b	b	a

S 0,4			
S 0,3	S 1,4		
{S,C}	Ø	S 2,4	
{A,C}	{B}	{B}	{A}
С	b	b	a

Exemple (4/8)

S	\rightarrow	AB
Α	\rightarrow	$CC \mid a \mid c$
В	\rightarrow	$BC \mid b$
C	\rightarrow	CB BA c

)		
S 0,4			
S 0,3	S 1,4		
S 0,2	S 1,3	S 2,4	
S 0,1	S 1,2	S 2,3	S 3,4
0.0,1			0.5,4
С	b	b	а

S 0,4			
S 0,3	S 1,4		
{S,C}	Ø	{C}	
{A,C}	{B}	{B}	{A}
С	b	b	a

Exemple (5/8)

 $S \rightarrow AB$

 $A \rightarrow CC \mid a \mid c$

 $B \rightarrow BC \mid b$

 $C \rightarrow CB \mid BA \mid c$

	1		
S 0,4			
\$ 0,3	S 2,4		
\$ 0,2	S 1,3	S 2,4	
S 0,1	S 1,2	\$ 2,3	S 3,4
с	b	b	a

S 0,4			
{C}	S 1,4		
{S,C}	Ø	{C}	
{A,C}	{B}	{B}	{A}
С	b	b	a


Exemple (6/8)

S 0,4			
S 0,3	S 1,4		
\$ 0,2	S 1,3	S 2,4	
S 0,1	S 1,2	S 2,3	\$ 3,4
С	b	b	a

S 0,4			
{C}	{B}		
{S,C}	Ø	{C}	
{A,C}	{B}	{B}	{A}
С	b	b	a

Exemple (7/8)

	1		
S 0,4			
S 0,3	S 1,4		
\$ 0,2	S 1,3	S 2,4	
\$ 0,1	S 1,2	S 2,3	S 3,4
	h	h	
С	b	b	а



Exemple (8/8)

s	0,4			
s	0,3	S 1,4		
S	0,2	S 1,3	S 2,4	
	0,2	01,5	02,4	
S	0,1	S 1,2	S 2,3	S 3,4
	С	b	b	а

{ S ,A,C}			
{C}	{B}		
{S,C}	ø	{C}	
{A,C}	{B}	{B}	{A}
6.7-7	τ-7	τ-7	
С	b	b	a